

Predicción de Readmisión Hospitalaria Temprana en Pacientes Diabéticos mediante Machine Learning Explicable y Privacidad Diferencial

Un enfoque interpretable para la estratificación del riesgo clínico utilizando SHAP, DiCE y Differential Privacy

Irene Alavés* Claudia Fernández** Eva Graña*** Blanca Xifra****

Grado en Ingeniería en Inteligencia Artificial — Escuela Politécnica Superior, Universidad de Alicante
Aprendizaje Avanzado — Curso 2025/2026

Resumen

Este trabajo presenta un sistema de aprendizaje automático para la predicción de readmisión hospitalaria temprana en pacientes con diabetes utilizando el dataset *Diabetes 130-US Hospitals*, compuesto por más de 100 000 registros clínicos reales.

Se evaluaron distintos modelos de clasificación bajo un escenario de fuerte desbalanceo de clases, aplicando técnicas de balanceo, validación cruzada estratificada y optimización mediante *GridSearchCV*. Además, se incorporaron técnicas de interpretabilidad y explicabilidad mediante SHAP y explicaciones contrafactuales con DiCE, así como un experimento de privacidad diferencial para analizar el compromiso entre privacidad y rendimiento predictivo.

Los resultados muestran que la aplicación de técnicas de balanceo mejora significativamente la detección de pacientes con riesgo de reingreso respecto al modelo *baseline*. Asimismo, SHAP permitió identificar patrones clínicamente coherentes en las predicciones del modelo, mientras que DiCE evidenció limitaciones relacionadas con la coherencia médica de determinadas explicaciones contrafactuales. Finalmente, los experimentos de privacidad diferencial mostraron una degradación progresiva del rendimiento al incrementar el nivel de protección de los datos.

Palabras clave: aprendizaje automático, readmisión hospitalaria, diabetes, explicabilidad, SHAP, DiCE, privacidad diferencial.

Índice

1. Introducción	4
2. Trabajo Relacionado	4
2.1. Predicción de reingreso hospitalario y aprendizaje automático en salud	5
2.2. Explicabilidad en modelos clínicos: SHAP	5
2.3. Explicaciones contrafactuales y DiCE	5
2.4. Privacidad diferencial en datos médicos	6

* iar44@alu.ua.es
** cfg67@alu.ua.es
*** egc135@alu.ua.es
**** bxm1@alu.ua.es

3. Descripción del Problema y los Datos	6
3.1. Definición formal de la tarea	6
3.2. Dataset: Contexto Clínico, Ontología y Estructura	7
3.2.1. Criterios de Cohorte y Dimensiones del Espacio de Características	7
3.2.2. Consideraciones Éticas y Privacidad de la Información	8
3.3. Análisis Exploratorio de Datos (EDA)	9
3.3.1. Estadística Descriptiva	9
3.3.1.1. Interpretación Clínica y Estadística:	10
3.3.2. Análisis de Distribuciones Univariadas	10
3.3.2.1. Interpretación Analítica y Repercusiones en el Modelado:	10
3.3.3. Dispersión Univariada y Análisis de Valores Atípicos	11
3.3.3.1. Interpretación Analítica y Repercusiones en el Modelado:	11
3.3.4. Relaciones Bivariadas y Análisis de Colinealidad	12
3.3.4.1. Interpretación Analítica y Repercusiones en el Modelado:	13
3.3.5. Dispersión Bivariada y Separabilidad Geométrica de Clases	13
3.3.5.1. Interpretación Analítica y Repercusiones en el Modelado:	14
3.3.6. Verificación Cuantitativa de Multicolinealidad	14
3.3.6.1. Resultados de la Auditoría e Implicaciones:	14
3.3.7. Desbalanceo Estructural y Representatividad de la Variable Objetivo	15
3.3.7.1. Interpretación Analítica y Repercusiones en el Modelado:	15
3.3.8. Reducción de Dimensionalidad y Proyección del Espacio Latente (PCA)	16
3.3.8.1. Interpretación Analítica y Repercusiones en el Modelado:	17
3.4. Problemáticas identificadas	17
4. Metodología	19
4.1. Preprocesamiento y Transformación de Datos	19
4.1.1. Limpieza de Características y Reestructuración Semántica	19
4.1.2. Protocolo de Partición y Estratificación	19
4.1.3. Arquitectura del Pipeline de Transformación	19
4.2. Modelo <i>baseline</i>	20
4.3. Tratamiento del desbalanceo	20
4.4. Protocolo de evaluación	21
4.5. Tratamiento de la problemática 1: Interpretabilidad y Explicabilidad	21
4.5.1. Interpretabilidad mediante SHAP	21
4.5.2. Explicabilidad contrafactual mediante DiCE	22
4.5.2.1. Formulación Matemática del Problema Contrafactual	23
4.5.2.2. Constricción del Espacio Accionable	23
4.6. Tratamiento de la problemática 2: Privacidad diferencial	23
5. Experimentos y Resultados	24
5.1. Configuración experimental	24
5.2. Resultados comparativos	24
5.2.1. Evaluación de la problemática 1: Interpretabilidad y Explicabilidad	25
5.2.1.1. Interpretabilidad global mediante SHAP	25
5.2.1.2. Interpretabilidad individual mediante SHAP	26
5.2.1.3. Explicabilidad contrafactual mediante DiCE	28
5.2.2. Problemática 2: Privacidad diferencial	29

6. Discusión	31
6.1. Interpretación de los resultados	31
6.1.1. Validación clínica de los resultados obtenidos	32
6.2. Limitaciones	33
6.3. Implicaciones éticas, legales y sociales	33
7. Conclusiones	34
A. Contribución individual	35
B. Enlace al repositorio	35
C. Uso de herramientas de IA generativa	36

1. Introducción

Orientación

La introducción debe responder a cuatro preguntas: (1) ¿Cuál es el problema y por qué es relevante? (2) ¿Qué implicaciones éticas, sociales o legales tiene? (3) ¿Qué se propone hacer este trabajo? (4) ¿Cómo se organiza el resto del documento? No es un resumen del trabajo, sino una motivación y contextualización.

La readmisión hospitalaria temprana en pacientes con diabetes constituye un problema relevante para los sistemas sanitarios, ya que puede estar asociada a una peor evolución clínica, mayor complejidad terapéutica y aumento de los costes asistenciales. En particular, los reingresos en menos de 30 días tras el alta hospitalaria pueden reflejar dificultades en la estabilización del paciente, problemas de seguimiento posterior o una coordinación asistencial insuficiente. Por ello, identificar de forma anticipada a los pacientes con mayor riesgo de reingreso puede ayudar a priorizar recursos clínicos y mejorar la atención tras el alta.

En este contexto, los modelos de *Machine Learning* pueden utilizarse como herramientas de apoyo a la decisión médica, ya que permiten detectar patrones complejos a partir de información demográfica, diagnóstica, farmacológica y hospitalaria. Sin embargo, su aplicación en salud plantea implicaciones éticas, sociales y legales especialmente relevantes. Un falso negativo podría implicar no detectar a un paciente realmente vulnerable, mientras que un falso positivo podría generar intervenciones o revisiones innecesarias. Además, al trabajar con datos clínicos sensibles, resulta necesario considerar la privacidad, la transparencia y la interpretabilidad del sistema.

Este trabajo propone el desarrollo de un modelo predictivo para estimar el riesgo de readmisión hospitalaria temprana en pacientes diabéticos a partir del dataset *Diabetes 130-US Hospitals*. El proyecto incluye el análisis exploratorio de los datos, el tratamiento del desbalanceo de clases, la optimización de modelos mediante *GridSearchCV* con validación cruzada de 5 particiones y la evaluación final sobre el conjunto de test. Además, se incorpora interpretabilidad mediante SHAP, explicabilidad contrafactual mediante DiCE y un experimento de privacidad diferencial para analizar el equilibrio entre protección de datos y rendimiento predictivo.

El resto del artículo se organiza como sigue. La Sección 2 revisa el trabajo relacionado. La Sección 3 describe el *dataset* y el análisis exploratorio. La Sección 4 detalla la metodología seguida. La Sección 5 presenta los resultados experimentales. La Sección 6 discute las implicaciones clínicas, éticas y técnicas. Finalmente, la Sección 7 recoge las conclusiones y posibles líneas de trabajo futuro.

2. Trabajo Relacionado

Orientación

No se trata de resumir trabajos uno a uno, sino de sintetizar la literatura de forma crítica: ¿qué se ha hecho antes?, ¿qué limitaciones tienen esos enfoques?, ¿cómo se sitúa este trabajo respecto al estado del arte? Organiza la sección por temática en lugar de por autor. Cita al menos 5–6 referencias de calidad [?].

La predicción de reingresos hospitalarios es una línea de trabajo relevante dentro del aprendizaje automático aplicado a salud, ya que permite anticipar situaciones de riesgo tras el alta y apoyar la planificación del seguimiento clínico. En pacientes con diabetes, este problema resulta especialmente importante debido a la naturaleza crónica de la enfermedad, la posible presencia de comorbilidades y la necesidad de ajustar adecuadamente el tratamiento tras el ingreso.

El conjunto de datos utilizado en este proyecto procede del estudio de Strack et al., en el que se analizaron registros clínicos de pacientes diabéticos para estudiar la relación entre la medición de HbA1c y las tasas de reingreso hospitalario. Este dataset fue posteriormente incorporado al repositorio UCI y se ha convertido en un recurso habitual para estudiar problemas de predicción clínica con datos tabulares heterogéneos [1].

2.1. Predicción de reingreso hospitalario y aprendizaje automático en salud

Los modelos de aprendizaje automático permiten trabajar con datos clínicos complejos formados por variables demográficas, diagnósticas, administrativas y farmacológicas. En el contexto de la readmisión hospitalaria, estos modelos pueden utilizarse como herramientas de detección para identificar pacientes que podrían requerir una revisión más cuidadosa antes del alta o un seguimiento posterior más estrecho.

Sin embargo, la aplicación de aprendizaje automático en medicina debe tratarse con cautela. El uso de modelos predictivos en salud no solo plantea un problema técnico de precisión, sino también cuestiones relacionadas con la validación clínica, la integración en los flujos de trabajo y la responsabilidad sobre las decisiones tomadas [2]. Por ello, en este trabajo el modelo no se plantea como un sustituto del profesional sanitario, sino como una herramienta de apoyo a la decisión clínica.

Además, la predicción de reingreso presenta una dificultad añadida: la clase de interés suele estar desbalanceada. En nuestro caso, los pacientes readmitidos en menos de 30 días representan solo el 11.16 % del total. Esto implica que métricas como la *accuracy* pueden resultar engañosas, ya que un modelo que predijera siempre la clase mayoritaria obtendría un valor elevado de *accuracy* sin detectar correctamente a los pacientes de mayor riesgo. Por este motivo, resulta necesario complementar la evaluación con métricas como el *recall*, el F1-score, el ROC-AUC y el PR-AUC.

2.2. Explicabilidad en modelos clínicos: SHAP

Una de las principales barreras para aplicar modelos de aprendizaje automático en salud es su falta de interpretabilidad. En un entorno clínico, no basta con obtener una probabilidad de riesgo; también es necesario comprender qué variables han contribuido a esa predicción. Esta necesidad es especialmente relevante cuando el modelo puede influir en decisiones relacionadas con el alta hospitalaria, la planificación del seguimiento o la asignación de recursos.

SHAP (*SHapley Additive exPlanations*) es una técnica de explicabilidad basada en valores de Shapley de la teoría de juegos. Su objetivo es asignar a cada variable una contribución concreta sobre la predicción realizada por el modelo [3]. Esta propiedad permite estudiar tanto el comportamiento global del modelo como predicciones individuales para pacientes concretos.

En este proyecto, SHAP se utiliza para analizar qué variables influyen más en la estimación del riesgo de reingreso y para interpretar casos individuales. Esta aproximación resulta adecuada porque permite pasar de una salida opaca del modelo a una explicación más comprensible para un posible usuario clínico. Aun así, las explicaciones SHAP deben entenderse como asociaciones aprendidas por el modelo, no como relaciones causales.

2.3. Explicaciones contrafactuales y DiCE

Además de conocer qué variables aumentan o reducen la predicción del modelo, en un contexto clínico puede resultar útil plantear escenarios alternativos. Las explicaciones contrafactuales responden precisamente a esta idea: identifican qué cambios mínimos en una instancia podrían modificar la predicción obtenida. Este enfoque ha sido propuesto como una forma de explicar decisiones automatizadas sin necesidad de abrir completamente la lógica interna del modelo [4].

DiCE (*Diverse Counterfactual Explanations*) amplía este planteamiento generando múltiples explicaciones contrafactuales diversas para una misma instancia [5]. Esto permite explorar varias vías alternativas para cambiar una predicción, en lugar de ofrecer una única explicación. En nuestro caso, DiCE se aplica a pacientes clasificados como de alto riesgo para estudiar si existen modificaciones en variables potencialmente accionables que reduzcan la probabilidad estimada de reingreso temprano.

No obstante, las explicaciones contrafactuales deben interpretarse con prudencia. Que el modelo sugiera que una modificación en una variable reduce el riesgo predicho no significa que dicha modificación produzca causalmente una mejora clínica. Por tanto, DiCE se utiliza en este trabajo como herramienta de análisis e interpretación del modelo, no como generador automático de recomendaciones médicas.

2.4. Privacidad diferencial en datos médicos

El uso de datos sanitarios plantea una problemática adicional relacionada con la privacidad. Aunque el dataset empleado está anonimizado y disponible para investigación, en un escenario real los registros clínicos contienen información especialmente sensible sobre los pacientes. El entrenamiento de modelos con este tipo de datos debe considerar el riesgo de exposición de información individual, especialmente cuando se trabaja con variables demográficas, diagnósticas y farmacológicas.

La privacidad diferencial proporciona un marco formal para limitar la influencia que puede tener un individuo concreto sobre la salida de un algoritmo [6]. De forma intuitiva, un modelo con privacidad diferencial debería comportarse de manera similar tanto si un paciente concreto forma parte del conjunto de entrenamiento como si no. El parámetro central de este enfoque es ϵ : valores más bajos implican mayor privacidad, pero normalmente también una mayor pérdida de rendimiento predictivo.

En este proyecto se emplea `diffprivlib`, una librería de IBM orientada a experimentar con mecanismos y modelos de privacidad diferencial en Python [7]. El objetivo de esta parte no es superar al modelo no privado, sino analizar empíricamente el compromiso entre privacidad y utilidad predictiva en un problema sanitario realista.

3. Descripción del Problema y los Datos

3.1. Definición formal de la tarea

Orientación

Define formalmente la tarea de aprendizaje: tipo de tarea (clasificación, regresión...), espacio de entrada y salida, y función objetivo.

La presente investigación aborda el fenómeno de la inestabilidad clínica post-hospitalaria mediante una tarea de **aprendizaje supervisado de clasificación binaria**. El objetivo técnico es la inducción de un modelo predictivo capaz de mapear un conjunto de vectores de características multidimensionales hacia una variable discreta que represente el riesgo de readmisión hospitalaria temprana. En el ámbito de la gestión sanitaria, este evento se define como aquel reingreso no planificado que ocurre en un lapso inferior a los 30 días posteriores al egreso del paciente.

Desde una perspectiva formal, el problema se define sobre un espacio de entrada $\mathcal{X} \subseteq \mathbb{R}^d$, donde el vector de características $\mathbf{x} \in \mathcal{X}$ tiene una dimensionalidad inicial de $d = 47$, abarcando descriptores demográficos, diagnósticos primarios y secundarios, y perfiles farmacoterapéuticos. El espacio de salida se define mediante el conjunto de etiquetas discretas $\mathcal{Y} = \{0, 1\}$. Buscamos

aproximar una función objetivo $f(\mathbf{x}) = P(y = 1|\mathbf{x})$ que minimice el riesgo empírico en el conjunto de datos $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$, compuesto por $n = 101,766$ encuentros hospitalarios.

La variable target, denominada `readmitted_binary`, es el resultado de un proceso de binarización de la variable categórica original `readmitted`. Esta reestructuración es fundamental para alinear el modelo de *Machine Learning* con los estándares de calidad de la atención médica (como los definidos por los *Centers for Medicare & Medicaid Services* en EE. UU.), donde la readmisión a 30 días es penalizada y considerada un fallo en la transición del cuidado. La función de mapeo lógico aplicada es:

$$y_i = \mathbb{I}(\text{readmitted}_i = '<30') = \begin{cases} 1 & \text{si readmitted}_i = '<30' \\ 0 & \text{e.o.c. (no readmitido o } > 30 \text{ días)} \end{cases} \quad (1)$$

Dada la naturaleza probabilística del dominio, la función de pérdida seleccionada para la optimización de los parámetros del algoritmo es la entropía cruzada binaria (*Binary Cross-Entropy Loss*), la cual penaliza de forma logarítmica las discrepancias entre las probabilidades estimadas por el modelo y las etiquetas reales del paciente.

3.2. Dataset: Contexto Clínico, Ontología y Estructura

Orientación

Describe el dataset: origen, licencia, número de instancias, número de features, variable objetivo y distribución de clases. Incluye también las consideraciones éticas sobre su uso.

El corpus de datos analizado es el *Diabetes 130-US Hospitals Analysis*, un *benchmark* conjunto de datos ampliamente utilizado en el ámbito de la informática médica, disponible a través del repositorio de la Universidad de California, Irvine (UCI Machine Learning Repository). Este conjunto de datos consolida un ingente volumen de Registros Electrónicos de Salud (EHR, por sus siglas en inglés) provenientes de la base de datos *Health Facts*, abarcando información de 130 instituciones hospitalarias distribuidas geográficamente por todo el territorio estadounidense. El horizonte temporal del dataset comprende una década ininterrumpida de práctica clínica (1999-2008), lo que permite a los algoritmos capturar tanto patrones transversales de morbilidad como posibles derivas temporales en los protocolos de tratamiento de la diabetes.

3.2.1. Criterios de Cohorte y Dimensiones del Espacio de Características

El diseño de la cohorte obedece a criterios de inclusión clínicos muy estrictos. Para que un encuentro hospitalario forme parte de este dataset, el paciente debió presentar un diagnóstico principal o secundario de diabetes, la duración de su estancia (LOS, *Length of Stay*) debió oscilar entre 1 y 14 días (indicativo de atención de agudos), y debió recibir pruebas de laboratorio o farmacoterapia durante su ingreso.

Bajo estas premisas, la matriz de datos resultante presenta una estructura tabular altamente dimensional con un volumen de **101,766 instancias**. El espacio de características original está compuesto por **47 atributos** predictivos. La ontología de estas variables captura de manera integral la heterogeneidad y complejidad operativa del manejo intrahospitalario del paciente diabético, dividiéndose en dos grandes familias tipológicas:

- **Descriptores Numéricos Continuos y Discretos (11 variables):** Estas variables actúan como *proxies* cuantitativos de la gravedad del cuadro clínico y de la intensidad en la utilización de los recursos hospitalarios.
 - *Intensidad diagnóstica y terapéutica:* Variables como `num_lab_procedures` (procedimientos de laboratorio) y `num_procedures` (procedimientos no de laboratorio, como cirugías) cuantifican el esfuerzo diagnóstico.

- *Polifarmacia*: El atributo `num_medications` indica el volumen de fármacos distintos administrados, un factor de riesgo ampliamente documentado en geriatría y medicina interna que suele correlacionar fuertemente con efectos adversos y reingresos.
- *Historial de cronicidad*: Contadores de visitas previas en el año anterior (`number_outpatient`, `number_emergency`, `number_inpatient`) que permiten al modelo inferir la fragilidad basal del paciente.

Estadísticamente, la mayoría de estos descriptores exhiben distribuciones marcadamente leptocúrticas y con asimetría positiva (*right-skewed*), un comportamiento clásico en teoría de colas aplicada a la salud, donde una gran masa de pacientes consume recursos moderados mientras una cola pesada de casos complejos demanda intervenciones masivas.

- **Atributos Categóricos y Nominales (36 variables)**: Conforman el eje vertebrador de la estratificación del riesgo clínico, aportando el contexto cualitativo del encuentro. Se subdividen en tres ejes fundamentales:
 - *Demografía y Morbilidad (ICD-9)*: Incluye edad agrupada en deciles, género y raza. El núcleo diagnóstico está representado por `diag_1`, `diag_2` y `diag_3`, que utilizan la Clasificación Internacional de Enfermedades (ICD-9) para codificar la enfermedad principal que motivó el ingreso y las comorbilidades concurrentes.
 - *Trayectoria Farmacológica*: Una matriz dispersa de 24 características correspondientes a principios activos antidiabéticos (ej. *metformin*, *glipizide*, *insulin*). Su valor reside en que no solo registran la prescripción, sino el ajuste terapéutico ("Up", "Down", "Steady", "No"), permitiendo modelar escaladas o desescaladas en la medicación debidas a descompensaciones glucémicas.
 - *Identificadores de Flujo Operativo*: Variables como `admission_source_id` (origen del ingreso: urgencias, derivación, etc.) y `discharge_disposition_id` (destino al alta: domicilio, residencia de ancianos, hospice). Un imperativo técnico en la fase de preprocesamiento es la coacción de estas variables, codificadas originalmente como enteros, hacia tipos de datos estrictamente nominales (variables *dummy*), para evitar que el modelo de Machine Learning asuma una magnitud ordinal espuria.

3.2.2. Consideraciones Éticas y Privacidad de la Información

El tratamiento de historiales clínicos electrónicos impone barreras éticas y legales críticas. En cumplimiento con la legislación estadounidense HIPAA (*Health Insurance Portability and Accountability Act*) bajo el método de *Safe Harbor*, el dataset fue purgado de todo identificador directo (Nombres, números de la seguridad social, direcciones exactas) previo a su liberación para fines de investigación académica. Se licenció bajo un marco de acceso abierto que permite el escrutinio de algoritmos sin comprometer el secreto médico profesional. Adicionalmente, ciertas variables como el peso de los individuos (`weight`) o detalles exactos de laboratorio sufren de altos grados de omisión, no por fallos de extracción, sino como reflejo de políticas de privacidad institucionales o variabilidad en los protocolos de documentación clínica entre los 130 hospitales analizados.

Tabla 1: Metadatos Estructurales y Resumen Ontológico del Corpus Médico.

Parámetro del Corpus	Especificación / Definición Técnica
Unidad Muestral	Encuentro hospitalario individual con atención especializada (<i>Acute Care</i>).
Volumen de Datos (N)	101,766 registros procesados.
Espacio de Entrada (d)	47 Atributos de base (previo a procesos de <i>Feature Engineering</i>).
Tipología Dinámica	11 Cuantitativas Continuas/Discretas 36 Categóricas/Nominales.
Definición del Target (y)	readmitted_binary : Variable de Bernoulli donde 1 denota riesgo agudo de readmisión en < 30 días.
Normativa y Ética	Datos desidentificados bajo metodología de anonimización estándar de salud. Licencia ODbL.
Limitaciones Latentes	Alta dimensionalidad y presencia de variables con ruido o censura clínica (ausencia de datos sistemática en biomarcadores).

3.3. Análisis Exploratorio de Datos (EDA)

El Análisis Exploratorio de Datos (EDA) se ha diseñado metodológicamente en distintas fases para auditar la calidad del corpus, entender sus distribuciones subyacentes e identificar posibles sesgos estructurales.

3.3.1. Estadística Descriptiva

El primer paso de la auditoría consistió en extraer los estadísticos de centralidad, dispersión y forma para las variables más representativas del dataset, acotando el análisis numérico a los descriptores de mayor impacto clínico para evitar la saturación de las métricas.

El fragmento de código utilizado para esta extracción se detalla en el Listado 1:

Listing 1: Extracción de estadística descriptiva para variables principales.

```

1 # Seleccionamos las 4 numericas principales para no saturar las graficas
2 num_features_plot = ['time_in_hospital', 'num_lab_procedures', 'num_procedures',
3                       'num_medications']
4
5 print("\n--- Estadística Descriptiva (Numericas Principales) ---")
6 display(df[num_features_plot].describe())
7
8 print("\n--- Estadística Descriptiva (Categoricas Top) ---")
9 display(df[['race', 'gender', 'age']].describe())

```

La ejecución de este bloque generó los resultados tabulados en la Tabla 2 y la Tabla 3.

Tabla 2: Estadística descriptiva de descriptores numéricos clínicos principales ($N = 101,766$).

Estadístico	time_in_hospital	num_lab_procedures	num_procedures	num_medications
Media	4.40	43.10	1.34	16.02
Desv. Estándar	2.99	19.67	1.71	8.13
Mínimo	1.00	1.00	0.00	1.00
Perc. 25 %	2.00	31.00	0.00	10.00
Mediana (50 %)	4.00	44.00	1.00	15.00
Perc. 75 %	6.00	57.00	2.00	20.00
Máximo	14.00	132.00	6.00	81.00

Tabla 3: Estadística descriptiva de variables demográficas categóricas.

Métrica	race	gender	age
Conteo válido	99,493	101,766	101,766
Clases únicas	5	3	10
Clase Moda (Top)	Caucasian	Female	[70-80)
Frecuencia Top	76,099 (76.48 %)	54,708 (53.76 %)	26,068 (25.62 %)

3.3.1.1. Interpretación Clínica y Estadística: Los resultados descriptivos arrojan conclusiones fundamentales sobre la naturaleza del paciente tipo en este corpus:

- **Polifarmacia y carga asistencial:** La media de medicamentos administrados se sitúa en 16.02, con un máximo extremo de 81 fármacos distintos en un solo ingreso. Esto denota un perfil de paciente altamente polimedicado, característico de la cronicidad avanzada. Asimismo, la alta dispersión en los procedimientos de laboratorio (hasta 132 pruebas) indica que el dataset contiene tanto ingresos rutinarios de estabilización como cuadros clínicos críticos.
- **Perfil demográfico y sesgos latentes:** El análisis categórico desvela un sesgo representacional evidente. Aproximadamente el 76.5 % de los registros con raza informada pertenecen a la categoría *Caucasian*. Además, la edad modal, ubicada en el decil [70-80), confirma que nos enfrentamos a una cohorte marcadamente geriátrica. La presencia de 3 clases únicas en la variable **gender** (habitualmente codificadas como *Male*, *Female* y *Unknown/Invalid*) ilustra el ruido inherente a los registros electrónicos de salud (EHR) del mundo real. Estas asimetrías demográficas imponen la necesidad de monitorizar el *algorithmic fairness* (equidad algorítmica) para asegurar que el modelo no penalice a minorías etarias o raciales.

3.3.2. Análisis de Distribuciones Univariadas

Para comprender la topología del espacio de características continuas y evaluar su desviación respecto a la normalidad estadística, se procedió a la estimación de la función empírica de densidad geométrica mediante histogramas univariados combinados con la estimación de densidad de kernel (KDE). El escrutinio de estas distribuciones es un prerequisite ineludible en el aprendizaje automático clínico, dado que la asimetría geométrica y la presencia de colas pesadas pueden degradar severamente la convergencia de algoritmos basados en gradiente y distorsionar las métricas topológicas basadas en distancias espaciales (como las normas L_1 o L_2).

El resultado visual de esta proyección estadística sobre los principales descriptores numéricos se expone en la Figura 1.

Figura 1: Estimación empírica de la densidad de probabilidad para los principales descriptores clínicos numéricos. Se advierte una desviación sistemática respecto a la distribución normal, con asimetrías positivas marcadas.

3.3.2.1. Interpretación Analítica y Repercusiones en el Modelado: La inspección visual de las densidades empíricas (Figura 1) corrobora las sospechas inferidas durante la extracción de la estadística descriptiva. Observamos un patrón estructural recurrente en variables críticas como `time_in_hospital`, `num_medications` y `num_procedures`:

- **Asimetría Positiva y Curtosis Inflada:** Las distribuciones están fuertemente sesgadas hacia la derecha (*right-skewed*) y son marcadamente leptocúrticas. La masa de probabilidad se concentra en los valores inferiores (ej., estancias de 2-4 días o 0 procedimientos no de

laboratorio), indicando que la gran mayoría de los ingresos corresponden a intervenciones estándar de baja complejidad.

- **Colas Pesadas (Heavy Tails):** Se aprecia una extensión longitudinal significativa en la cola derecha de las distribuciones. En términos clínicos, esta "cola" mapea a la subpoblación de pacientes críticos que experimentan estancias prolongadas o requieren una polimedicación masiva (hasta > 80 fármacos). Desde una perspectiva de *Machine Learning*, estos valores no deben ser tratados como valores atípicos espurios (*outliers* ruidosos) sujetos a eliminación, sino como la "señal intrínseca" de la morbilidad severa.
- **Implicaciones para el Preprocesamiento:** La ausencia de normalidad gaussiana descarta el uso directo de modelos lineales puros (como la Regresión Logística estándar o SVM lineal) a menos que se apliquen mapeos no lineales previos (transformaciones logarítmicas, de Yeo-Johnson o discretización por cuantiles). Por el contrario, este análisis justifica empíricamente la preelección técnica de algoritmos basados en la partición recursiva del espacio de características, como los ensambles basados en árboles (*Random Forest*, *Gradient Boosting*), los cuales son intrínsecamente invariantes a las transformaciones monotónicas de la escala y altamente robustos ante la varianza inflada por estas colas pesadas.

3.3.3. Dispersión Univariada y Análisis de Valores Atípicos

Como complemento indispensable a la estimación de densidad, se procedió a evaluar la dispersión de las variables continuas y la prevalencia de valores extremos mediante diagramas de caja (*boxplots*). Esta técnica topológica permite visualizar de manera robusta la mediana, el rango intercuartílico (IQR) y la densidad de observaciones que escapan a los límites de aceptabilidad estadística estándar ($Q_3 + 1,5 \times \text{IQR}$).

La proyección de la dispersión para los descriptores numéricos de mayor relevancia se presenta en la Figura 2.




Figura 2: Diagramas de caja univariados. Se evidencia una alta concentración de valores atípicos superiores (*upper outliers*) en la carga farmacológica y analítica.

3.3.3.1. Interpretación Analítica y Repercusiones en el Modelado: La evaluación espacial de las cajas y bigotes arroja conclusiones determinantes sobre la heterogeneidad de la cohorte clínica:

- **Prevalencia de Valores Extremos Superiores:** Las variables `num_lab_procedures` y `num_medications` exhiben una franja densa de puntos (*outliers*) por encima de su bigote superior. En `num_medications`, el IQR se sitúa entre 10 y 20 fármacos, pero observamos una dispersión de casos que alcanza hasta 81 medicamentos distintos. De forma análoga, existen pacientes sometidos a más de 130 procedimientos de laboratorio.

- **Justificación Clínica de la Varianza Extrema:** En el dominio de la medicina interna, estos "valores atípicos" no representan ruido estocástico o errores de medición que deban ser purgados (*data clipping*). Al contrario, codifican la existencia de una subpoblación de pacientes pluripatológicos de extrema fragilidad, posiblemente ingresados en unidades de cuidados intensivos (UCI) o experimentando episodios agudos severos (como sepsis o shock metabólico).
- **Implicaciones metodológicas:** La presencia de valores extremos justifica el uso de transformaciones robustas en el preprocesamiento. Por este motivo, se empleó **RobustScaler**, que utiliza la mediana y el rango intercuartílico en lugar de la media y la desviación típica, reduciendo así la influencia de valores extremos sin eliminar casos clínicamente relevantes.

3.3.4. Relaciones Bivariadas y Análisis de Colinealidad

Una vez caracterizadas las distribuciones marginales (univariadas), la auditoría topológica del espacio de características exige evaluar las dependencias conjuntas entre los descriptores continuos. La detección temprana de alta redundancia informativa —fenómeno conocido como multicolinealidad— es crítica, puesto que viola el supuesto de independencia lineal de las características. En algoritmos paramétricos, una colinealidad severa infla la varianza de los estimadores (incrementando el *Variance Inflation Factor*, VIF), lo que desestabiliza los gradientes durante el entrenamiento y arruina la interpretabilidad intrínseca de los pesos del modelo.

Para cuantificar estas dependencias lineales, se ha computado la matriz de correlación pareada utilizando el coeficiente de correlación de Pearson (r). La proyección matricial en formato de mapa de calor (*heatmap*) se expone en la Figura 3.




Figura 3: Matriz de correlación de Pearson para características clínicas continuas. La diagonal principal representa la autocorrelación ($r = 1$). No se advierten dependencias lineales severas que comprometan la estabilidad del espacio.

3.3.4.1. Interpretación Analítica y Repercusiones en el Modelado: El escrutinio de la matriz de correlación arroja conclusiones muy favorables para la arquitectura del sistema predictivo:

- **Ausencia de Colinealidad Estructural:** El hallazgo más destacable es la inexistencia de coeficientes de correlación que superen el umbral de alerta crítico (típicamente establecido en $|r| > 0,8$ o $0,9$). La correlación máxima detectada se sitúa en un rango moderado (en torno a $r \approx 0,46$), lo que certifica que cada variable numérica aporta una "señal" ortogonal razonablemente única al modelo.
- **Coherencia Clínica de las Dependencias Moderadas:** Las correlaciones positivas más notables se observan entre la duración de la estancia (`time_in_hospital`) y la carga terapéutica (`num_medications`), así como con el volumen de pruebas de laboratorio (`num_lab_procedures`). Estas asociaciones tienen un sentido clínico inequívoco: a mayor tiempo de internamiento de un paciente diabético, mayor es la probabilidad de que se prescriban ajustes farmacológicos y se requiera un monitoreo analítico continuado. Es una correlación sintomática de la complejidad del caso, no una redundancia matemática espuria.
- **Implicaciones Metodológicas:** Desde el punto de vista del *pipeline* de *Machine Learning*, la ausencia de alta colinealidad estructural nos permite prescindir de técnicas agresivas de reducción de dimensionalidad espacial (como el Análisis de Componentes Principales, PCA) previas al modelado. Asimismo, garantiza que si se llegasen a utilizar técnicas de explicabilidad basadas en perturbación u omisión de variables (como SHAP o *Permutation Importance*), la atribución de importancia no se verá severamente distorsionada por el efecto de variables *proxy* o sustitutas.

3.3.5. Dispersión Bivariada y Separabilidad Geométrica de Clases

Con el fin de evaluar empíricamente la separabilidad geométrica del problema en el espacio continuo, se proyectó la distribución conjunta de las dos variables que exhibieron el mayor nivel de covarianza en el análisis matricial previo: la duración de la estancia hospitalaria (`time_in_hospital`) y la complejidad terapéutica (`num_medications`). La inspección de esta proyección bidimensional, condicionada por la etiqueta de clase (riesgo de readmisión), resulta imperativa para anticipar la topología de la frontera de decisión que el algoritmo deberá aproximar.

La Figura 4 expone esta relación de forma dual. El panel izquierdo ilustra la distribución conjunta estructural, mientras que el panel derecho superpone la variable objetivo binaria para auditar la separabilidad.




Figura 4: Proyección de dispersión (*scatter plot*) bivariada. El panel derecho evidencia un solapamiento espacial absoluto entre la clase negativa (azul, sin reingreso) y la clase positiva de alto riesgo (rojo, reingreso en < 30 días).

3.3.5.1. Interpretación Analítica y Repercusiones en el Modelado: El análisis visual topológico de esta proyección arroja conclusiones críticas que condicionan ineludiblemente la arquitectura del sistema de *Machine Learning*:

- **Dinámica Clínica y Heterocedasticidad:** El panel no condicionado (izquierdo) constata visualmente la correlación detectada anteriormente. La nube de puntos adopta una trayectoria ascendente congruente con la praxis médica: prolongar el internamiento conlleva una exposición a un abanico más amplio de principios activos. Además, se observa una ligera dispersión en abanico (heterocedasticidad); a medida que los días de hospitalización se acercan al límite de 14, la varianza en el número de medicamentos se dispara, evidenciando una alta heterogeneidad en el manejo de complicaciones agudas.
- **Solapamiento Masivo de Clases (*Class Overlap*):** El panel condicionado (derecho) revela la verdadera dificultad del desafío predictivo. Observamos una imbricación espacial casi total entre los pacientes que sufrieron readmisiones tempranas (rojo) y aquellos estabilizados (azul). No existe ninguna densidad segregada o *cluster* puro; los casos positivos están distribuidos de manera estocástica a lo largo de todo el espectro de la clase mayoritaria.
- **Intratabilidad mediante Separadores Lineales:** De manera axiomática, este gráfico demuestra que no existe ningún hiperplano (o en este subespacio $\mathbb{R}^2$, una línea recta) capaz de separar ambas poblaciones con un margen de error aceptable.
- **Justificación Metodológica para Algoritmos Avanzados:** Esta constatación empírica descarta definitivamente la viabilidad de modelos paramétricos lineales (como la Regresión Logística de primer orden sin interacciones complejas) como solucionadores óptimos. Demuestra que el riesgo de readmisión hospitalaria es un fenómeno multifactorial fuertemente no lineal que no depende de magnitudes aisladas, justificando la adopción de algoritmos con alta capacidad de aproximación no lineal, como los ensambles basados en árboles de decisión (*Random Forest*, *Gradient Boosting Trees*). Del mismo modo, este nivel de complejidad justifica la necesidad de aplicar técnicas de explicabilidad (XAI) posteriormente, ya que la lógica deductiva del modelo final escapará a la simple intuición visual.

3.3.6. Verificación Cuantitativa de Multicolinealidad

Como corolario al análisis topológico de las relaciones bivariadas, se procedió a realizar una auditoría algorítmica estricta para descartar formalmente la presencia de multicolinealidad severa. Aunque la inspección visual de la matriz de covarianza (Figura 3) sugería una independencia estructural razonable entre los descriptores, el rigor metodológico exige una validación cuantitativa que prevenga la inestabilidad numérica. En arquitecturas paramétricas, la colinealidad extrema corrompe el cálculo de los gradientes y condiciona negativamente la inversión de matrices (como la matriz Hessiana), derivando en estimadores de varianza infinita.

Para esta verificación, se estableció un umbral de tolerancia crítico estandarizado en $|r| \geq 0,8$. En la teoría estadística del aprendizaje, este límite marca la frontera a partir de la cual el Factor de Inflación de la Varianza (VIF, por sus siglas en inglés) comienza a degradar de forma inaceptable la interpretabilidad algorítmica.

3.3.6.1. Resultados de la Auditoría e Implicaciones: El escrutinio computacional sobre el subespacio completo de variables continuas arrojó un total exacto de **0 instancias de correlación problemática**. Este diagnóstico matemático de independencia lineal aporta garantías cruciales para el diseño del sistema:

- **Eficiencia Informacional del Espacio de Entrada:** Garantiza empíricamente que no existe redundancia de información severa. Cada métrica clínica continua (desde el tiempo

de hospitalización hasta el volumen de procedimientos) captura una proyección ortogonal, o semi-ortogonal, de la varianza del paciente, maximizando la entropía útil del conjunto de datos.

- **Garantías para la Interpretabilidad Post-Hoc (XAI):** La ausencia de colinealidad extrema asegura que, en etapas posteriores del *pipeline*, los métodos de explicabilidad (como los valores SHAP o las explicaciones contrafactuales de DiCE) resultarán matemáticamente estables. Si existieran variables altamente correlacionadas, los algoritmos de atribución de importancia tenderían a diluir el peso predictivo estocásticamente entre dichas variables *proxy*, arruinando la confiabilidad de la explicación médica.

3.3.7. Desbalanceo Estructural y Representatividad de la Variable Objetivo

El último paso de la auditoría exploratoria consiste en la evaluación empírica de la variable objetivo binarizada (`readmitted_binary`). En la teoría del aprendizaje estadístico, la distribución marginal de las clases de salida determina el sesgo inductivo basal del modelo (*prior probability*). Un desequilibrio severo altera la geometría de la función de coste y compromete seriamente la convergencia hacia un óptimo global que sea clínicamente útil.

La Figura 5 ilustra la distribución de frecuencias absolutas y relativas para los dos estados posibles del encuentro hospitalario.




Figura 5: Distribución marginal de la variable objetivo. Se constata un desbalanceo estructural agudo (ratio $\approx 8 : 1$), donde la clase minoritaria crítica representa apenas el 11.2% de la cohorte.

3.3.7.1. Interpretación Analítica y Repercusiones en el Modelado: La confirmación visual de esta asimetría radical (88.8% frente a 11.2%) trasciende la mera descripción estadística y establece los axiomas metodológicos para el resto de la investigación:

- **Dominancia en la Función de Pérdida:** Al utilizar funciones de optimización estándar empíricas, los gradientes calculados durante el entrenamiento estarán subyugados por la clase negativa mayoritaria (pacientes sin reingreso temprano). Sin una intervención metodológica, el algoritmo convergerá hacia un atractor trivial: predecir sistemáticamente la clase 0 para minimizar la pérdida de manera perezosa (*lazy learning*).
- **La Paradoja de la Precisión (*Accuracy Paradox*):** Este gráfico invalida matemáticamente el uso de la exactitud global (*Accuracy*) como métrica de evaluación. Un clasificador

ingenuo que etiquete a todos los pacientes como "No Readmitidos." alcanzaría automáticamente un 88.8 % de acierto, una cifra estadísticamente alta pero clínicamente inútil. Por consiguiente, la evaluación algorítmica deberá pivotar estrictamente hacia métricas insensibles al sesgo de prevalencia, priorizando el *Recall* (Sensibilidad), el *F1-Score* de la clase minoritaria y el Área Bajo la Curva Precision-Recall (PR-AUC).

- **Asimetría de la Matriz de Costes Clínicos:** Desde la perspectiva de la gestión sanitaria, los errores de predicción no son isométricos. Un Falso Positivo (etiquetar como alto riesgo a un paciente estable) implica un sobrecoste moderado en monitorización ambulatoria. Sin embargo, un Falso Negativo (ignorar a un paciente de alto riesgo) puede derivar en un reingreso crítico evitable o en el empeoramiento agudo de la patología subyacente.
- **Mandato de Intervención Algorítmica:** La magnitud del desbalanceo justificada en esta figura hace perentoria la aplicación de técnicas paliativas en el *pipeline* de datos. Esto fundamentará la adopción de hiperparámetros de penalización asimétrica (como `class_weight='balanced'`) en las funciones de coste o el uso de umbrales de decisión dinámicos en la fase de inferencia.

3.3.8. Reducción de Dimensionalidad y Proyección del Espacio Latente (PCA)

Como colofón al análisis exploratorio continuo, se procedió a evaluar la estructura global de los datos mediante una técnica de reducción de dimensionalidad no supervisada. Se aplicó el Análisis de Componentes Principales (PCA) sobre el subespacio numérico (previamente imputado mediante la mediana y normalizado espacialmente con *StandardScaler*) para proyectar la varianza multidimensional en un hiperplano bidimensional. El objetivo empírico de esta técnica es verificar si la varianza intrínseca de los datos clínicos se alinea, de manera natural, con el vector objetivo (riesgo de readmisión), o si existen clústeres latentes que faciliten la clasificación.

La Figura 6 muestra la proyección ortogonal de una muestra representativa ($n = 10,000$) sobre los dos primeros componentes principales (PC1 y PC2).




Figura 6: Proyección bidimensional mediante PCA. El subespacio de máxima varianza no logra desenredar (*disentangle*) las distribuciones de ambas clases, mostrando un solapamiento topológico total.

3.3.8.1. Interpretación Analítica y Repercusiones en el Modelado: La topología resultante de esta transformación ortogonal proporciona los axiomas finales para el diseño de la arquitectura predictiva:

- **Ortogonalidad respecto a la Variable Objetivo:** La gráfica demuestra de manera incontestable que las direcciones de máxima varianza en los datos clínicos (los autovectores de la matriz de covarianza) **no discriminan** el riesgo de readmisión. La clase de alto riesgo (puntos rojos) no forma un *manifold* o clúster diferenciado, sino que se distribuye de manera difusa y homogénea sobre la masa central de la clase negativa (puntos azules).
- **Geometría del Paciente Crítico:** La nube de puntos presenta un núcleo denso (pacientes estándar) y una clara dispersión longitudinal o "cola" hacia valores positivos de las componentes. Clínicamente, este gradiente captura la transición hacia pacientes de extrema fragilidad (aquellos con largas estancias y polifarmacia severa). Sin embargo, el hecho de que haya puntos azules en el extremo de esa cola indica que la alta intensidad asistencial, por sí sola, no garantiza un reingreso; depende de interacciones ocultas.
- **Insuficiencia del Subespacio Continuo:** Al constatar la intratabilidad lineal en los componentes principales, se concluye formalmente que el modelo predictivo no podrá basarse únicamente en variables continuas de intensidad (tiempo, número de medicamentos). El poder predictivo (*predictive power*) necesario para romper este solapamiento residirá ineludiblemente en el espacio categórico de alta dimensionalidad: las combinaciones específicas de diagnósticos (ICD-9), demografía y ajustes precisos en la farmacoterapia antidiabética.
- **Rechazo de Clasificadores Lineales Simples:** Esta proyección dictamina la inviabilidad absoluta de emplear clasificadores paramétricos simples (como LDA, QDA o Regresión Logística de primer orden) y confirma que se requerirá proyectar los datos a dimensiones superiores (mediante *Kernel Trick* en SVM) o particionar el espacio recursivamente (árboles de decisión y ensambles) para capturar la función de frontera altamente irregular y no lineal que rige este problema de salud pública.

3.4. Problemáticas identificadas

Orientación

Justifica aquí qué problemáticas son relevantes para este problema concreto. La argumentación debe basarse en: (1) el contexto de uso real del sistema (¿quién usa el modelo?, ¿sobre quién toma decisiones?), (2) las características del dataset (¿hay atributos sensibles?, ¿está desbalanceado?), y (3) las obligaciones legales aplicables (RGPD, AI Act).

La convergencia entre los hallazgos empíricos del Análisis Exploratorio de Datos (EDA) y la naturaleza crítica del dominio de aplicación (salud pública) impone restricciones severas sobre el ciclo de vida del modelo predictivo. Un sistema de *Machine Learning* diseñado para predecir el riesgo de readmisión hospitalaria operará en un entorno de alto impacto (*high-stakes environment*), donde los usuarios finales son facultativos médicos y administradores hospitalarios, y las decisiones recaen sobre una población vulnerable: pacientes crónicos pluripatológicos.

En este contexto operan normativas jurídicas de obligado cumplimiento, como el Reglamento General de Protección de Datos (RGPD) y la inminente Ley de Inteligencia Artificial de la Unión Europea (*AI Act*), la cual clasifica explícitamente a los sistemas de IA en el ámbito de la salud como de "Alto Riesgo" (*High-Risk AI Systems*).

A partir de esta intersección clínico-legal y topológica, se han identificado y priorizado las dos siguientes problemáticas a resolver en este proyecto:

- **Opacidad Algorítmica y la Necesidad de Explicabilidad Contrafactual (XAI):**

- *Justificación Topológica*: Como se demostró en las proyecciones bivariadas y en el análisis PCA (Sección 3.3), las clases presentan un solapamiento espacial absoluto. Esta intratabilidad lineal fuerza el uso de arquitecturas altamente complejas y no lineales (ensambles de árboles o redes neuronales) para lograr un rendimiento predictivo aceptable frente al desbalanceo. Sin embargo, estos modelos actúan como cajas negras" (*black-boxes*).
- *Justificación Clínica y Legal*: Un facultativo no puede basar el alta o la retención de un paciente únicamente en un *score* probabilístico opaco; necesita una justificación mecanicista que respalde la heurística médica. Además, el Artículo 22 del RGPD consagra el "derecho a la explicación" ante decisiones automatizadas que produzcan efectos jurídicos o significativos en el individuo.
- *Abordaje (DiCE)*: Para resolver esta fricción, no basta con explicaciones globales de importancia de variables. Se implementará una técnica de Explicaciones Contrafactuales (*Diverse Counterfactual Explanations*, DiCE). Este enfoque transita del "¿por qué el modelo predijo alto riesgo?". al "¿qué variables accionables (ej. `num_medications`, pautas de insulina) deberían modificarse en el mundo real para que este paciente en concreto cruce el umbral hacia el bajo riesgo?".

■ Vulnerabilidad de Datos Sensibles y Privacidad Diferencial:

- *Justificación de los Datos*: El *dataset* analizado está compuesto por Registros Electrónicos de Salud (EHR) que incluyen una granularidad extrema sobre la vida del paciente: raza, género, edad, diagnósticos concurrentes (ICD-9) y regímenes farmacológicos detallados. A pesar de estar desidentificados, la literatura de ciberseguridad ha demostrado que la intersección de estas variables altamente dimensionales hace a los pacientes susceptibles a ataques de vinculación (*linkage attacks*) y ataques de inferencia de pertenencia (*membership inference attacks*), donde un adversario podría deducir si un individuo específico, con una enfermedad concreta, formó parte del conjunto de entrenamiento.
- *Justificación Legal*: El RGPD (Art. 5 y Art. 25) exige la "Privacidad desde el Diseño" la minimización de datos. En el paradigma biomédico moderno, la centralización de bases de datos sin garantías matemáticas de anonimato es inaceptable.
- *Abordaje (ϵ -Differential Privacy)*: Para mitigar este riesgo sistémico, se explorará la integración de **Privacidad Diferencial**. Se aplicarán mecanismos de inyección de ruido estocástico durante el entrenamiento del modelo predictivo para garantizar, bajo una cota matemática estricta (ϵ), que la presencia o ausencia de un único encuentro hospitalario no altere significativamente los parámetros aprendidos por el clasificador. Se evaluará rigurosamente el *trade-off* ineludible entre el grado de privacidad garantizado y la degradación de la utilidad predictiva (AUC-ROC y *Recall*).

4. Metodología

Orientación

Esta sección debe ser suficientemente detallada para que el trabajo sea reproducible. Describe el pipeline completo, justifica cada decisión de diseño, e incluye la formulación matemática de las técnicas que lo requieran.

4.1. Preprocesamiento y Transformación de Datos

Orientación

Describe la cadena de preprocesamiento: imputación de valores ausentes, escalado, codificación de variables categóricas, división train/test y estratificación.

El diseño de un *pipeline* de preprocesamiento robusto es una etapa crítica para garantizar la integridad del aprendizaje y evitar la fuga de datos (*data leakage*). Dada la heterogeneidad y el ruido detectado en el conjunto de datos de diabetes, se ha implementado un flujo de transformación determinista y modular utilizando la arquitectura `ColumnTransformer` de *scikit-learn*.

4.1.1. Limpieza de Características y Reestructuración Semántica

En primer lugar, se procedió a una poda de características basada en criterios de utilidad informativa y calidad de datos. Siguiendo el diagnóstico del EDA, se eliminaron de forma permanente las columnas `weight`, `max_glu_serum` y `A1Cresult`, debido a que su tasa de nulidad (superior al 80 %) las inhabilitaba para cualquier proceso de inferencia estadística. Asimismo, se descartaron los identificadores administrativos (`encounter_id` y `patient_nbr`) para evitar que el modelo aprenda patrones espurios basados en el orden de registro o el historial de pacientes recurrentes.

Un paso metodológico fundamental fue la corrección del tipo de dato para las variables `admission_type_id`, `discharge_disposition_id` y `admission_source_id`. Aunque estas columnas se presentan originalmente como valores enteros, representan categorías nominales puras. Por tanto, se forzó su conversión al tipo *object* para asegurar que el motor de codificación las trate como entidades categóricas discretas y no como magnitudes ordinales.

4.1.2. Protocolo de Partición y Estratificación

Para la evaluación del rendimiento, el dataset se dividió en un conjunto de entrenamiento (80 %) y un conjunto de prueba (20 %), resultando en dimensiones de **81,412 instancias para entrenamiento** y **20,354 para validación**.

Dada la prevalencia minoritaria de la clase positiva (11.2 %), se aplicó una **partición estratificada**. Este procedimiento garantiza que la distribución de la variable objetivo se mantenga idéntica en ambos subconjuntos, preservando la representatividad del fenómeno de readmisión temprana y evitando sesgos de muestreo que podrían infravalorar el riesgo clínico en el conjunto de test.

4.1.3. Arquitectura del Pipeline de Transformación

Se ha diseñado un transformador por columnas diferenciado para los dos tipos de naturaleza de datos identificados (8 variables numéricas y 36 categóricas):

- **Sub-pipeline Numérico:** La imputación de valores ausentes se realizó mediante la **mediana**, una medida de tendencia central más robusta que la media ante distribuciones

asimétricas. Para el escalado, se seleccionó el **RobustScaler**. A diferencia del escalado estándar, este método utiliza el rango intercuartílico (IQR) para normalizar los datos, lo cual es imperativo en este dataset dada la alta densidad de valores atípicos (*outliers*) detectados en el número de medicaciones y procedimientos (ver Sección 3.3). Esto garantiza que la varianza extrema de los casos clínicos complejos no distorsione el espacio de características.

- **Sub-pipeline Categórico:** Se aplicó una imputación basada en la **moda** (valor más frecuente) para tratar los nulos residuales. Posteriormente, las variables se transformaron mediante **One-Hot Encoding**. Para dotar al sistema de resiliencia ante datos futuros, se configuró el parámetro `handle_unknown='ignore'`, asegurando que si el modelo encuentra una categoría no vista durante el entrenamiento (ej. una especialidad médica nueva en el conjunto de test), el sistema no colapse y asigne un vector nulo a dicha entrada.

El resultado final es un espacio de entrada de alta dimensionalidad, listo para la inducción de modelos, donde las variables numéricas han sido desensibilizadas ante valores extremos y las categóricas han sido proyectadas a un espacio euclídeo interpretable por algoritmos lineales y no lineales.

4.2. Modelo *baseline*

Orientación

El baseline es el punto de referencia contra el que compararás las técnicas aplicadas. Elige un modelo estándar apropiado para la tarea y justifica su elección.

Como modelo baseline se utilizó una regresión logística sin técnicas específicas de balanceo. Este modelo se seleccionó por tratarse de un clasificador lineal ampliamente utilizado en tareas de clasificación binaria y por ofrecer un alto grado de interpretabilidad sobre las variables clínicas.

Además, la regresión logística constituye una referencia habitual en problemas médicos tabulares, permitiendo comparar posteriormente el efecto del tratamiento del desbalanceo y de modelos más complejos.

Sin embargo, debido al fuerte desbalanceo presente en la variable objetivo, el modelo *baseline* presentaba limitaciones importantes en la detección de la clase minoritaria, mostrando una baja capacidad para identificar pacientes readmitidos tempranamente y una fuerte tendencia hacia la clase mayoritaria.

4.3. Tratamiento del desbalanceo

Debido al fuerte desbalanceo presente en la variable objetivo, se consideraron técnicas específicas de balanceo con el objetivo de mejorar la detección de la clase minoritaria.

En concreto, se empleó una regresión logística con ponderación de clases (`class_weight="balanced"`), que ajusta automáticamente la importancia relativa de cada clase durante el entrenamiento. Este enfoque penaliza en mayor medida los errores cometidos sobre la clase minoritaria, reduciendo el sesgo hacia la clase mayoritaria observado en el modelo *baseline*.

Adicionalmente, se evaluó un modelo basado en *Random Forest* con balanceo de clases, con el objetivo de analizar si un modelo no lineal basado en ensambles de árboles podía mejorar el rendimiento en la detección de pacientes con riesgo de reingreso hospitalario.

La selección final del modelo se realizó considerando conjuntamente el *recall*, el F1-score y las métricas ROC-AUC y PR-AUC obtenidas mediante validación cruzada estratificada.

4.4. Protocolo de evaluación

La evaluación de los modelos se llevó a cabo mediante una división estratificada en conjuntos de entrenamiento y test, con el fin de preservar la distribución original de las clases.

El conjunto de datos se dividió en un **80 % para entrenamiento** y un **20 % para evaluación final** sobre test.

Para la optimización de hiperparámetros se utilizó **GridSearchCV** junto con **validación cruzada estratificada de 5 folds** sobre el conjunto de entrenamiento.

La selección del mejor modelo se realizó priorizando la capacidad de detección de la clase minoritaria, dado que el objetivo principal del sistema es identificar pacientes con riesgo de reingreso hospitalario.

Debido al fuerte desbalanceo del dataset, la **accuracy** no se consideró una métrica suficiente, ya que un clasificador que predijera siempre la clase mayoritaria obtendría valores elevados de exactitud sin detectar correctamente los casos de readmisión temprana.

Por este motivo, se utilizaron métricas más adecuadas para evaluar el rendimiento sobre la clase minoritaria, incluyendo las siguientes métricas:

- *Precision*
- *Recall*
- F1-score
- ROC-AUC
- PR-AUC

Estas métricas permiten evaluar de forma más adecuada el comportamiento del modelo sobre la clase minoritaria. En particular, el **recall** resulta especialmente relevante en un contexto sanitario, ya que minimizar los falsos negativos es importante para detectar pacientes con riesgo de reingreso hospitalario.

4.5. Tratamiento de la problemática 1: Interpretabilidad y Explicabilidad

4.5.1. Interpretabilidad mediante SHAP

La primera problemática abordada en este trabajo es la interpretabilidad del modelo predictivo. En un contexto sanitario no basta con que el sistema proporcione una probabilidad de reingreso, también es necesario comprender qué variables han influido en esa predicción. Esta necesidad resulta importante cuando el modelo puede utilizarse como herramienta de apoyo para priorizar seguimiento clínico, revisar pacientes antes del alta o asignar recursos hospitalarios.

Para abordar esta cuestión se ha utilizado SHAP (*SHapley Additive exPlanations*), una técnica de interpretabilidad basada en los valores de Shapley de la teoría de juegos cooperativos. SHAP permite descomponer la predicción de un modelo en contribuciones individuales atribuibles a cada variable de entrada.

Formalmente, la predicción de una instancia puede expresarse como:

$$f(x) = \phi_0 + \sum_{i=1}^M \phi_i \quad (2)$$

donde:

- $f(x)$ representa la predicción final del modelo para una instancia concreta.
- ϕ_0 corresponde al valor base del modelo (predicción media global).
- ϕ_i representa la contribución de cada variable i sobre la predicción final.
- M es el número total de variables utilizadas por el modelo.

Los valores SHAP positivos aumentan la probabilidad predicha de reingreso, mientras que los valores negativos reducen dicha probabilidad. De esta forma, SHAP permite identificar qué variables empujan la predicción hacia un mayor o menor riesgo para cada paciente concreto.

En este proyecto, SHAP se aplicó sobre el modelo final seleccionado, una Regresión Logística balanceada optimizada mediante *GridSearchCV*. Tras entrenar el modelo con los datos de entrenamiento, se extrajo el preprocesador ajustado y se transformaron los datos de test al espacio final generado por el proceso de codificación *One-Hot Encoding*. Como resultado, el conjunto de datos transformado quedó representado por 2402 variables.

Dado que el modelo seleccionado es lineal, se utilizó **LinearExplainer**, un explicador específico de SHAP optimizado para modelos lineales. Este enfoque permite calcular de forma eficiente las contribuciones individuales de cada variable sobre las predicciones del clasificador.

El análisis de interpretabilidad se realizó en dos niveles. En primer lugar, se estudió la importancia global de las variables para identificar los factores que más influyen en el comportamiento general del modelo. En segundo lugar, se analizaron explicaciones individuales mediante gráficos *waterfall*, con el objetivo de comprender por qué pacientes concretos recibieron una determinada probabilidad de reingreso.

La utilización de SHAP resulta muy útil en este problema por varios motivos. En primer lugar, permite interpretar predicciones individuales en un entorno clínico donde los profesionales sanitarios necesitan comprender cómo está tomando decisiones el modelo antes de confiar en sus resultados. Además, ayuda a identificar si el modelo está aprendiendo patrones clínicamente coherentes o si está detectando asociaciones que podrían resultar problemáticas. Por último, SHAP permite generar explicaciones locales incluso en espacios de alta dimensionalidad, como el obtenido tras el preprocesamiento del dataset médico utilizado en este proyecto.

4.5.2. Explicabilidad contrafactual mediante DiCE

Orientación

Describe la técnica aplicada. Incluye la formulación matemática cuando sea necesaria para entender el método. Justifica por qué esta técnica es adecuada para el problema y el dataset elegidos.

La opacidad intrínseca de los modelos de *Machine Learning* avanzados (como los ensambles no lineales o redes neuronales) constituye una barrera infranqueable para su adopción en entornos clínicos de alto riesgo. Para resolver esta problemática estructural, se ha implementado un marco de explicabilidad basado en Explicaciones Contrafactuales (*Diverse Counterfactual Explanations*, DiCE). A diferencia de los enfoques de atribución de características tradicionales (como SHAP o LIME) que ofrecen una interpretación retrospectiva y puramente correlacional, DiCE proporciona una interpretabilidad prospectiva e intervencionista.

4.5.2.1. Formulación Matemática del Problema Contrafactual

El paradigma contrafactual responde a la pregunta algorítmica: *¿Cuál es la perturbación mínima necesaria en el vector de características de un paciente para invertir la predicción del modelo?* Formalmente, dada una instancia original $\mathbf{x}$ clasificada en una clase indeseada (ej. $f(\mathbf{x}) = 1$, alto riesgo de readmisión), el objetivo es generar un conjunto de k vectores contrafactuales $\mathcal{C} = \{\mathbf{c}_1, \mathbf{c}_2, \dots, \mathbf{c}_k\}$ tales que $f(\mathbf{c}_i) = 0$.

La generación de la matriz contrafactual se define como un problema de optimización sobre una función de pérdida conjunta, formulada de la siguiente manera:

$$\mathcal{L}(\mathcal{C}, \mathbf{x}) = \frac{1}{k} \sum_{i=1}^k \text{yloss}(f(\mathbf{c}_i), y^*) + \frac{\lambda_1}{k} \sum_{i=1}^k \text{dist}(\mathbf{c}_i, \mathbf{x}) - \lambda_2 \text{dpp_diversity}(\mathcal{C}) \quad (3)$$

Los componentes de esta optimización garantizan la viabilidad clínica de la solución:

- **Convergencia Predictiva (yloss):** Minimiza la distancia entre la predicción del contrafactual $f(\mathbf{c}_i)$ y la clase objetivo $y^* = 0$ (bajo riesgo), típicamente mediante pérdida *hinge* o entropía cruzada.
- **Proximidad Elástica (dist):** Penaliza los desplazamientos excesivos en el espacio de características. Utiliza una norma mixta L_1/L_{MAD} (Desviación Absoluta Mediana) para variables continuas, garantizando que el escenario sugerido sea alcanzable en la realidad anatómica del paciente.
- **Diversidad Topológica (dpp_diversity):** Emplea Procesos Puntuales Determinantales (DPP) para maximizar la distancia espacial entre los k contrafactuales, ofreciendo al clínico un arsenal terapéutico heterogéneo (múltiples vías de tratamiento) en lugar de soluciones redundantes.

4.5.2.2. Constricción del Espacio Accionable

La principal aportación metodológica de esta implementación es la partición estricta del espacio de características $\mathcal{X}$ en dos subespacios disjuntos: el inmutable ($\mathcal{X}_{imm}$) y el accionable ($\mathcal{X}_{act}$). Para garantizar que la IA no proponga cambios imposibles o éticamente problemáticos (como modificar la raza o reducir la edad de un paciente), el optimizador genético de DiCE fue restringido para alterar **exclusivamente** las siguientes variables clínicas de control hospitalario ($\mathcal{X}_{act}$): `time_in_hospital`, `num_medications`, `num_lab_procedures`, `num_procedures`, `insulin_change`, y `diabetesMed`.

4.6. Tratamiento de la problemática 2: Privacidad diferencial

La segunda problemática abordada en este trabajo es la privacidad de los datos clínicos utilizados durante el entrenamiento del modelo predictivo. En entornos sanitarios, los conjuntos de datos contienen información sensible, por lo que resulta fundamental limitar el riesgo de filtración o memorización de información individual por parte del modelo.

Para abordar esta problemática se empleó un enfoque basado en **privacidad diferencial**, una técnica que introduce ruido controlado durante el proceso de entrenamiento con el objetivo de proteger la contribución individual de cada paciente dentro del conjunto de datos.

Para el estudio de privacidad diferencial, se trabajó con un subconjunto reducido de **18 variables originales**, con el objetivo de disminuir la complejidad del entrenamiento bajo restricciones de privacidad diferencial.

Esta reducción de dimensionalidad permite limitar parcialmente el impacto del ruido introducido durante el entrenamiento y mejorar la estabilidad del modelo bajo mecanismos de privacidad.

El conjunto de entrenamiento inicial presentaba un fuerte desbalanceo, con 72326 instancias de la clase mayoritaria y 9086 de la clase minoritaria. Para el entrenamiento bajo privacidad diferencial, se realizó un balanceo del dataset, obteniendo finalmente un total de 18172 muestras balanceadas.

Tras el preprocesamiento, los datos utilizados presentan una dimensionalidad final de 18172×83 en entrenamiento y 20354×83 en test.

Asimismo, se aplicó una técnica de **clipping** de norma, estableciendo un valor máximo de 10 con el objetivo de limitar la influencia individual de cada instancia durante el entrenamiento.

El clipping restringe la magnitud máxima de los gradientes asociados a cada muestra, evitando que observaciones individuales tengan una influencia excesiva durante el proceso de entrenamiento del modelo.

Finalmente, se evaluó el impacto de distintos niveles de privacidad sobre el rendimiento predictivo del modelo, analizando el compromiso existente entre protección de la información y capacidad de generalización.

5. Experimentos y Resultados

Orientación

Esta sección presenta los resultados sin interpretarlos (la interpretación va en la Sección 6). Usa tablas comparativas que permitan ver claramente la diferencia entre el baseline y cada intervención. Reporta siempre media $\pm$ desviación estándar cuando uses validación cruzada.

5.1. Configuración experimental

Todos los experimentos se realizaron utilizando una semilla aleatoria fija ($SEED = 42$) con el objetivo de garantizar la reproducibilidad de los resultados.

Los modelos fueron implementados en Python utilizando principalmente las librerías *scikit-learn*, *pandas*, *NumPy*, *SHAP* y *DiCE*.

La optimización de hiperparámetros se realizó mediante *GridSearchCV* con validación cruzada estratificada de 5 folds sobre el conjunto de entrenamiento.

Listing 2: Semilla aleatoria utilizada durante los experimentos.

```
1 import numpy as np
2 SEED = 42
3 np.random.seed(SEED)
```

5.2. Resultados comparativos

El dataset presenta un desbalanceo significativo, con un 11.2% de casos positivos correspondientes a reingresos tempranos frente a un 88.8% de pacientes no readmitidos antes de 30 días.

La Tabla 4 muestra la comparación entre el modelo *baseline* y los modelos balanceados optimizados mediante *GridSearchCV* y validación cruzada estratificada de 5 folds.

Tabla 4: Comparación de rendimiento entre los modelos evaluados.

Modelo	Precision	Recall	F1	ROC-AUC	PR-AUC
LR Baseline	0.480	0.020	0.040	—	—
LR Balanceada + GridSearchCV	0.183	0.578	0.278	0.683	0.226
Random Forest Balanceado + GridSearchCV	0.176	0.619	0.274	0.674	0.211

Los resultados muestran que el modelo *baseline* obtiene una *accuracy* elevada debido al fuerte desbalanceo del conjunto de datos, pero presenta una capacidad muy limitada para detectar pacientes con reingreso temprano, alcanzando un *recall* de únicamente 0.020 para la clase positiva.

Tras aplicar técnicas de balanceo y optimización de hiperparámetros, ambos modelos mejoran significativamente la detección de pacientes de riesgo. El modelo *Random Forest* balanceado alcanza el mayor *recall* (0.619), mientras que la Regresión Logística balanceada obtiene el mejor equilibrio global entre *F1-score*, *ROC-AUC* y *PR-AUC*.

Debido a este equilibrio entre rendimiento predictivo e interpretabilidad, se seleccionó la Regresión Logística balanceada optimizada mediante *GridSearchCV* como modelo final del proyecto.

La Figura 7 muestra la matriz de confusión correspondiente al modelo final seleccionado.




Figura 7: Matriz de confusión del modelo final seleccionado.

El modelo final obtiene 12 241 verdaderos negativos, 5 842 falsos positivos, 959 falsos negativos y 1 312 verdaderos positivos.

5.2.1. Evaluación de la problemática 1: Interpretabilidad y Explicabilidad

5.2.1.1. Interpretabilidad global mediante SHAP

Para analizar de forma global qué variables influyen más en las predicciones del modelo, se aplicó SHAP sobre la Regresión Logística balanceada seleccionada como modelo final.

El análisis se realizó sobre una muestra de 1000 pacientes del conjunto de test, utilizando los valores SHAP calculados tras el preprocesamiento completo del pipeline. Después del *One-Hot*

Encoding, el espacio de entrada quedó representado por 2402 variables transformadas.




Figura 8: Importancia global de variables según SHAP para el modelo final seleccionado.

La Figura 8 muestra el *summary plot* de SHAP, donde se representan las variables con mayor impacto global sobre la predicción del riesgo de reingreso temprano. Cada punto corresponde a un paciente individual, mientras que el color indica el valor relativo de la variable (valores altos o bajos) y la posición horizontal refleja la contribución de dicha variable a la predicción del modelo.

Los resultados muestran que las variables con mayor influencia en la predicción están relacionadas principalmente con el historial clínico y la complejidad médica del paciente.

Entre las variables más relevantes destacan el número de ingresos hospitalarios previos (`number_inpatient`), los cambios recientes en la medicación (`change_Ch`), determinadas especialidades médicas como medicina interna (`medical_specialty_InternalMedicine`) y distintas variables asociadas al tratamiento de la diabetes, como `diabetesMed` e `insulin`.

También aparecen variables relacionadas con el tipo de alta hospitalaria y la edad avanzada del paciente.

El análisis global mediante SHAP permite identificar las variables más influyentes en las predicciones del modelo y ayuda a comprender de forma más clara cómo toma sus decisiones.

5.2.1.2. Interpretabilidad individual mediante SHAP

Una vez analizadas las variables más influyentes a nivel global, se estudió el comportamiento del modelo sobre pacientes individuales mediante SHAP. Esta técnica permite analizar qué variables influyen en cada predicción realizada por el modelo, mostrando qué factores aumentan o reducen la probabilidad estimada de reingreso temprano.

Las explicaciones individuales son relevantes en entornos sanitarios, ya que permiten comprender por qué un paciente concreto ha sido clasificado con un determinado nivel de riesgo. De esta forma, el modelo deja de comportarse como una caja negra y sus resultados pueden ser revisados con mayor criterio por un profesional clínico.

Tras seleccionar como modelo final la Regresión Logística balanceada optimizada mediante *GridSearchCV*, se aplicó SHAP sobre una muestra de 1000 pacientes del conjunto de test. En primer lugar, se analizó un paciente individual con una probabilidad intermedia de reingreso temprano. En este caso, el gráfico *waterfall* permitió observar qué variables contribuían a elevar o reducir la predicción del modelo para ese paciente concreto.




Figura 9: Explicación individual mediante SHAP para un paciente del conjunto de test con probabilidad intermedia de reingreso temprano.

El modelo estimó para este paciente una probabilidad aproximada de reingreso temprano del 19.9 %. El análisis SHAP mostró que variables como determinados diagnósticos clínicos codificados (*diag_1_584*, *diag_2_276*), la edad avanzada (*age_[80-90)*) y la atención en medicina interna contribuían al incremento del riesgo predicho. Al mismo tiempo, otras variables reducían la probabilidad final estimada, compensando los factores de riesgo.

Posteriormente, se estudió el paciente clasificado con mayor riesgo de reingreso dentro de la muestra analizada. Para este paciente, el modelo estimó una probabilidad de reingreso temprano del 88.13 %. Esta predicción representa el caso de mayor riesgo detectado por el modelo dentro de la muestra utilizada para el análisis SHAP.




Figura 10: Explicación individual mediante SHAP para el paciente con mayor riesgo predicho de reingreso temprano.

El análisis SHAP mostró que las variables que más incrementaban el riesgo de este paciente estaban relacionadas principalmente con el número de ingresos hospitalarios previos (`number_inpatient` = 4), determinados diagnósticos clínicos codificados (`diag_3_453`, `diag_1_403`, `diag_2_585`), el tipo de alta hospitalaria (`discharge_disposition_id_3`) y la edad avanzada (`age_[70-80)`). También aparecieron variables asociadas a la atención en medicina interna y al tratamiento de la diabetes.

Desde un punto de vista clínico, este perfil resulta coherente con un paciente de alta vulnerabilidad: una persona de edad avanzada, con antecedentes de hospitalizaciones y presencia de patologías asociadas. Este tipo de explicación permite pasar de una predicción opaca a una interpretación más comprensible, donde el modelo no solo indica que el paciente tiene un riesgo elevado, sino también qué factores están contribuyendo a dicha predicción.

Estos resultados muestran que SHAP no solo permite interpretar la dirección de la predicción, sino también evaluar si el modelo está aprendiendo patrones clínicamente coherentes, aumentando así la confianza en su posible utilización como herramienta de apoyo a la decisión médica.

5.2.1.3. Explicabilidad contrafactual mediante DiCE

Para evaluar empíricamente la viabilidad de DiCE como sistema de Soporte a la Decisión Clínica (CDSS), se aisló una instancia crítica del conjunto de validación, codificada como "Paciente Cero". Este registro corresponde a una mujer caucásica, del decil geriátrico [80-90) años, ingresada por Medicina Interna. El paciente presenta un perfil de severidad elevado: 4 días de estancia, polifarmacia activa (17 medicamentos distintos), 40 procedimientos de laboratorio previos y prescripción activa de medicación diabética (`diabetesMed` = Yes).

El modelo clasificador *baseline* evaluó a este paciente asignándole una probabilidad predictiva de readmisión temprana del **55.40 %**, clasificándolo como caso de riesgo según el umbral de decisión de 0.5. ($y = 1$).

Al ejecutar el motor de optimización contrafactual bajo las restricciones del espacio accionable ($\mathcal{X}_{act}$), el algoritmo iteró hasta hallar tres escenarios ($k = 3$) capaces de reducir la probabilidad por debajo del umbral crítico (0,5), invirtiendo la clasificación. La Tabla 5 detalla las intervenciones descubiertas y su impacto probabilístico.

Tabla 5: Resumen de explicaciones contrafactuales para el Paciente Cero (probabilidad original: 0.5508).

ID escenario	Probabilidad final	Reducción	Predicción	Variables modificadas
Base	0,5508	—	1 (riesgo)	num_procedures: 0, num_lab: 40, insulin: Up, diabetesMed: Yes
Contrafactual 1	0,4949	−0,0559	0	num_procedures, diabetesMed
Contrafactual 2	0,4969	−0,0539	0	num_lab_procedures, diabetesMed
Contrafactual 3	0,4910	−0,0598	0	insulin, diabetesMed

Para verificar el cumplimiento ético de las restricciones impuestas al modelo espacial, se auditó la naturaleza de las características perturbadas por el algoritmo. La Tabla 6 confirma que el optimizador operó de manera estrictamente determinista dentro de los márgenes accionables.

Tabla 6: Auditoría de variables modificadas por DiCE.

ID contrafactual	Atributos modificados	Variables no accionables	Variables accionables alteradas
Contrafactual 1	2	0	[num_procedures, diabetesMed]
Contrafactual 2	2	0	[num_lab_procedures, diabetesMed]
Contrafactual 3	2	0	[insulin, diabetesMed]

5.2.2. Problemática 2: Privacidad diferencial

Para evaluar el impacto de la privacidad diferencial, se comparó una regresión logística convencional con tres modelos equivalentes entrenados mediante privacidad diferencial, usando distintos valores de ϵ . El objetivo de este experimento no es obtener el mejor modelo global del proyecto, sino analizar el compromiso entre privacidad y utilidad predictiva en un escenario sanitario.

El experimento se realizó sobre una versión reducida y controlada del conjunto de variables. Se utilizaron 18 variables originales, de las cuales 8 eran numéricas y 10 categóricas. Tras aplicar imputación, escalado y codificación *one-hot*, el espacio final quedó formado por 83 variables. Además, para reducir el efecto del desbalanceo, el entrenamiento se realizó sobre un subconjunto balanceado de 18 172 muestras. La evaluación se mantuvo sobre el conjunto de test original, con 20 354 instancias, para conservar una estimación más realista del comportamiento del modelo.

La Tabla 7 muestra los resultados obtenidos para el modelo convencional y los tres modelos con privacidad diferencial.

Tabla 7: Comparación entre regresión logística convencional y modelos con privacidad diferencial.

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC
LR sin DP	0.6654	0.1822	0.5729	0.2764	0.6760	0.2193
DP $\epsilon = 0,1$	0.5672	0.1262	0.4861	0.2004	0.5385	0.1252
DP $\epsilon = 1,0$	0.5656	0.1339	0.5288	0.2136	0.5695	0.1419
DP $\epsilon = 10,0$	0.6610	0.1763	0.5553	0.2677	0.6631	0.1969

El modelo sin privacidad diferencial obtiene el mejor rendimiento general dentro de este experimento, con un *ROC-AUC* de 0.6760, un *recall* de 0.5729 y un F1-score de 0.2764. Estos valores sirven como referencia para medir la pérdida de utilidad asociada a la introducción de privacidad diferencial.

El modelo con $\epsilon = 0,1$ presenta la mayor caída de rendimiento. Su *ROC-AUC* baja hasta 0.5385 y el F1-score hasta 0.2004. Este resultado es coherente con el funcionamiento esperado de la privacidad diferencial: un valor bajo de ϵ implica una protección más estricta de la información individual, pero introduce más ruido durante el entrenamiento y reduce la capacidad predictiva del modelo.

Con $\epsilon = 1,0$, el rendimiento mejora ligeramente respecto a $\epsilon = 0,1$, especialmente en *recall*, que aumenta de 0.4861 a 0.5288. Sin embargo, el modelo todavía queda por debajo del rendimiento del modelo sin privacidad diferencial. Esto indica que el nivel de privacidad sigue afectando de forma apreciable a la separación entre pacientes readmitidos y no readmitidos.

El mejor resultado entre los modelos privados se obtiene con $\epsilon = 10,0$. En este caso, el modelo alcanza un *ROC-AUC* de 0.6631, un *recall* de 0.5553 y un F1-score de 0.2677. Estos valores son cercanos a los del modelo convencional, aunque la garantía de privacidad es menos estricta que en los casos anteriores.

La Figura 11 resume visualmente este comportamiento. Se observa que las tres métricas representadas disminuyen al introducir privacidad diferencial fuerte y se recuperan progresivamente al aumentar ϵ .




Figura 11: Trade-off entre privacidad y rendimiento para distintos valores de ϵ .

Para analizar con más detalle el comportamiento del mejor modelo privado, se estudió la matriz de confusión del modelo con $\epsilon = 10,0$, mostrada en la Figura 12.




Figura 12: Matriz de confusión del modelo con privacidad diferencial y $\epsilon = 10,0$.

Este modelo obtiene 12 193 verdaderos negativos, 5 890 falsos positivos, 1 010 falsos negativos y 1 261 verdaderos positivos. En términos clínicos, esto significa que detecta 1 261 de los 2 271 pacientes que realmente fueron readmitidos en menos de 30 días. Sin embargo, también clasifica como de riesgo a 5 890 pacientes que finalmente no fueron readmitidos tempranamente.

Este resultado refleja una tensión habitual en modelos clínicos de cribado. Por un lado, detectar pacientes de riesgo es importante porque permite priorizar seguimiento o revisión adicional. Por otro lado, un número elevado de falsos positivos puede aumentar la carga asistencial y generar intervenciones innecesarias. En este contexto, el modelo privado con $\epsilon = 10,0$ mantiene una capacidad de detección razonable respecto al modelo no privado, aunque sigue siendo necesario valorar si el coste de los falsos positivos sería aceptable en un entorno hospitalario real.

6. Discusión

Orientación

Interpreta los resultados en el contexto del problema real: ¿qué significan para los usuarios afectados por el sistema? Analiza las limitaciones con rigor y evita afirmaciones genéricas sobre ética; las implicaciones deben ser específicas y estar fundamentadas en los resultados obtenidos.

6.1. Interpretación de los resultados

En lo que respecta a la explicabilidad contrafactual (DiCE), los resultados demuestran la viabilidad de traducir las predicciones de una caja negra probabilística en una herramienta prospectiva de Soporte a la Decisión Clínica (CDSS). En el caso de estudio analizado, el algoritmo logró descender el riesgo de readmisión de la paciente del 55.08 % a una franja de seguridad ($< 50\%$) mediante modificaciones parsimoniosas, alterando únicamente dos variables por escenario. Para los usuarios finales del sistema (facultativos y gestores hospitalarios), esto supone un cambio de paradigma: se transita de recibir una simple alerta de riesgo a disponer de un "mapa de intervenciones" que aísla palancas de control accionables (como el ajuste en `num_procedures`,

`num_lab_procedures` o `insulin`) para estabilizar proactivamente al paciente antes de firmar su alta.

Sin embargo, la traducción empírica de estas vías contrafactuales revela un sesgo clínico crítico inherente al aprendizaje estadístico: la optimización de una función de coste matemática ignora por completo la homeostasis fisiológica humana. Un análisis profundo arroja un diagnóstico alarmante si estas sugerencias se aplicasen de forma automatizada:

- **La Falacia de la Desprescripción (Contrafactual 3):** La IA sugiere interrumpir por completo el tratamiento con insulina (`insulin` → No) y retirar la medicación antidiabética (`diabetesMed` → No). En el registro original de la paciente, la insulina estaba en fase de escalada terapéutica (`insulin` = Up), indicando una descompensación glucémica aguda. Matemáticamente, el modelo asume que no tomar medicación equivale a estar sano. Clínicamente, retirar la insulina a una paciente octogenaria en pleno pico de descompensación provocaría un shock hiperglucémico letal.
- **El Atajo Estocástico (Contrafactuales 1 y 2):** De forma aún más anómala, el algoritmo propone como solución someter a la paciente a 6 intervenciones/procedimientos mayores (`num_procedures` → 6) o elevar la intensidad analítica a 117 pruebas de laboratorio (`num_lab_procedures` → 117), manteniendo su estancia en solo 4 días. El modelo ha correlacionado una altísima intensidad diagnóstica con un control exhaustivo del paciente. Sin embargo, extraer 117 analíticas o realizar 6 cirugías/procedimientos a una anciana en 96 horas es una imposibilidad física y una negligencia médica.

Para los pacientes afectados, estas decisiones demuestran que DiCE es una herramienta de auditoría algorítmica excepcional para entender qué variables penalizan al individuo en el espacio latente del modelo, pero en ningún caso constituye un prescriptor automatizado. El modelo confunde sistemáticamente el síntoma con la causa, demostrando empíricamente que correlación no implica causalidad. Toda sugerencia contrafactual exige un filtro de plausibilidad biológica dictado por el criterio médico humano, validando el paradigma de *Human-in-the-Loop*.

6.1.1. Validación clínica de los resultados obtenidos

Uno de los aspectos más importantes del proyecto consistió en analizar si las variables identificadas por el modelo como más influyentes tenían sentido desde un punto de vista clínico real. Este análisis resulta muy relevante en aplicaciones médicas, ya que un modelo predictivo no solo debe ofrecer un rendimiento estadístico aceptable, sino también generar resultados coherentes e interpretables para los profesionales sanitarios.

Los resultados obtenidos mediante SHAP muestran que varias de las variables con mayor impacto sobre el riesgo de reingreso están relacionadas con factores clínicos coherentes en pacientes diabéticos complejos. La variable `number_inpatient`, correspondiente al número de ingresos hospitalarios previos, aparece como uno de los factores más relevantes en múltiples predicciones individuales. Este resultado tiene sentido clínico, ya que los pacientes con antecedentes de hospitalizaciones frecuentes suelen presentar mayor fragilidad, peor control de la enfermedad o una situación clínica más inestable.

También destacaron variables relacionadas con diagnósticos médicos codificados, como `diag_1`, `diag_2` y `diag_3`. Este comportamiento resulta coherente, ya que determinadas complicaciones metabólicas, cardiovasculares o renales asociadas a la diabetes pueden incrementar la probabilidad de reingreso hospitalario. De la misma forma, la aparición de variables relacionadas con medicina interna resulta razonable, ya que estos servicios suelen atender a pacientes con elevada complejidad clínica.

Del mismo modo, variables relacionadas con el tratamiento diabético y los cambios en la medicación pueden interpretarse como indicadores indirectos de inestabilidad terapéutica. No obstante, es importante destacar que SHAP explica asociaciones aprendidas por el modelo, pero no demuestra relaciones causales. Por tanto, estas variables deben interpretarse como señales estadísticas de riesgo y no como causas directas del reingreso hospitalario.

Los resultados sugieren que el modelo ha aprendido patrones clínicamente coherentes con el conocimiento médico existente. Esta coherencia aumenta la confianza en el sistema como posible herramienta de apoyo a la decisión clínica, siempre que sus predicciones sean supervisadas e interpretadas por profesionales sanitarios y no utilizadas como mecanismos automáticos de decisión.

6.2. Limitaciones

El sistema predictivo y las técnicas aplicadas presentan limitaciones no triviales, derivadas tanto de las restricciones del *dataset* como de las técnicas de interpretabilidad y explicabilidad utilizadas:

- **Limitaciones interpretativas de SHAP:** Aunque SHAP permite explicar las predicciones del modelo mediante contribuciones individuales de las variables, estas explicaciones representan asociaciones aprendidas por el clasificador y no relaciones causales reales. Además, en espacios de alta dimensionalidad o con variables muy correlacionadas, las atribuciones de importancia pueden verse afectadas por dependencias entre características.
- **El atajo estocástico en DiCE:** La IA ignora la plausibilidad biológica. Propuso como solución viable elevar el volumen de pruebas a 117 analíticas manteniendo el mismo tiempo de ingreso (4 días), lo cual es una imposibilidad física. Además también sugirió como método para encontrar pacientes más eliminar la medicación antidiabética, lo cual no tiene ningún tipo de sentido ya que si se la quitásemos a una anciana en etapa de descompensación provocaría un shock hiperglucémico letal.
- **Decaimiento Temporal (*Temporal Drift*):** El *dataset* refleja la práctica médica de 1999 a 2008. Las revoluciones farmacológicas y actualizaciones de protocolos de la última década limitan la validez externa del modelo en la actualidad.
- **Falta de variables socioeconómicas (SDOH):** El reingreso depende críticamente del nivel de ingresos y el apoyo familiar domiciliario. Al carecer de estos datos, el modelo aproxima el riesgo basándose exclusivamente en métricas biológicas.
- **Sesgos Sistémicos y Representacionales:** Los datos pertenecen a hospitales estadounidenses (mediados por seguros privados como Medicare), lo que dificulta su transferencia a sistemas públicos. Además, la sobrerrepresentación de pacientes caucásicos (76 %) compromete la equidad del modelo frente a minorías.

6.3. Implicaciones éticas, legales y sociales

Desde el prisma de la explicabilidad, el uso de DiCE evidencia el riesgo crítico de implementar IA en entornos de Alto Riesgo (según el *AI Act*) sin supervisión. Aunque la generación de contrafactuales ayuda a cumplir con el "derecho a la explicación" (Art. 22 del RGPD), aceptar ciegamente las sugerencias del modelo por sesgo de automatización derivaría en negligencias médicas letales. Esto fundamenta la obligación legal y social de operar bajo un paradigma *Human-in-the-Loop*, donde el facultativo es el único validador de las topologías matemáticas que propone la máquina.

7. Conclusiones

Orientación

Síntesis de las contribuciones en 3–4 párrafos. Lecciones aprendidas. Líneas de trabajo futuro concretas y bien motivadas (no genéricas como “aplicar deep learning”).

El trabajo ha permitido desarrollar un sistema predictivo para estimar el riesgo de readmisión hospitalaria temprana en pacientes con diabetes utilizando el dataset *Diabetes 130-US Hospitals*. A partir de una tarea de clasificación binaria, se ha transformado la variable original `readmitted` para identificar específicamente los reingresos en menos de 30 días. El análisis inicial mostró un fuerte desbalanceo de clases, con solo un 11.16 % de pacientes pertenecientes a la clase positiva, lo que condicionó tanto el entrenamiento como la evaluación de los modelos.

Una de las principales lecciones aprendidas es que, en problemas médicos desbalanceados, la *accuracy* puede resultar engañosa. El modelo *baseline* alcanzaba una exactitud elevada, cercana al 89 %, pero apenas detectaba pacientes readmitidos tempranamente. Por este motivo, se priorizaron métricas más adecuadas para la clase minoritaria, como el *recall*, el F1-score, el ROC-AUC y el PR-AUC. Tras aplicar `class_weight='balanced'` y optimización de hiperparámetros mediante *GridSearchCV* con validación cruzada de 5 particiones, se seleccionó como modelo final una Regresión Logística balanceada, por ofrecer un equilibrio entre rendimiento clínico e interpretabilidad.

Desde el punto de vista de la interpretabilidad, SHAP permitió analizar tanto el comportamiento global del modelo como predicciones individuales. En el caso del paciente con mayor riesgo dentro de la muestra analizada, el modelo estimó una probabilidad de reingreso temprano del 88.13 %, y las variables que más influyeron en dicha predicción estuvieron relacionadas con ingresos previos, diagnósticos clínicos, edad avanzada, tipo de alta y tratamiento médico. Estos resultados son clínicamente plausibles, aunque deben entenderse como asociaciones aprendidas por el modelo y no como relaciones causales.

También se han explorado dos conceptos importantes para el uso responsable de inteligencia artificial en salud: la explicabilidad y la privacidad. Las explicaciones contrafactuales mediante DiCE permitieron analizar escenarios alternativos para un paciente clasificado como de riesgo, reduciendo la probabilidad estimada de reingreso desde aproximadamente 0.55 hasta valores cercanos a 0.49. Estos cambios afectaron a variables consideradas accionables o parcialmente accionables, como `num_medications`, `num_lab_procedures` y `diabetesMed`. Sin embargo, estos resultados no deben interpretarse como recomendaciones médicas directamente, ya que DiCE muestra asociaciones aprendidas por el modelo y no relaciones causales. En un contexto clínico real, cualquier sugerencia derivada de este tipo de explicaciones tendría que ser revisada por profesionales sanitarios.

En cuanto a la privacidad, el experimento con privacidad diferencial permitió observar el equilibrio entre la protección de los datos y el rendimiento predictivo del modelo. El modelo sin privacidad diferencial obtuvo un *ROC-AUC* de 0.6760 y un F1-score de 0.2764, mientras que con $\epsilon = 0,1$ el rendimiento descendió hasta un *ROC-AUC* de 0.5385 y un F1-score de 0.2004. Por otro lado, al utilizar un valor menos restrictivo como $\epsilon = 10,0$, el modelo consiguió recuperar parte de su capacidad predictiva, alcanzando un *ROC-AUC* de 0.6631 y un F1-score de 0.2677. Estos resultados muestran que aumentar el nivel de privacidad puede afectar negativamente al rendimiento del modelo, por lo que la elección de ϵ debería ajustarse según las necesidades clínicas, legales e institucionales de cada contexto.

Como posibles líneas futuras de trabajo, sería interesante validar el modelo utilizando datos hospitalarios más recientes y procedentes de distintos sistemas sanitarios, con el objetivo de

comprobar si mantiene su capacidad de generalización en otros contextos. También podría ser útil incorporar variables relacionadas con el seguimiento tras el alta, el apoyo familiar, la adherencia al tratamiento, el acceso a atención primaria o la situación socioeconómica, ya que todos estos factores pueden influir de manera importante en el riesgo de reingreso.

Además, resultaría interesante explorar enfoques de privacidad más avanzados, como el aprendizaje federado o la combinación de *federated learning* con privacidad diferencial, lo que permitiría entrenar modelos entre distintos hospitales sin necesidad de centralizar los datos clínicos. Por último, antes de utilizar el modelo en un entorno real, sería necesario realizar una validación clínica supervisada por profesionales sanitarios y analizar si las explicaciones generadas mediante SHAP y DiCE son realmente comprensibles, útiles y seguras dentro del entorno hospitalario.

Referencias

- [1] B. Strack, J. P. DeShazo, C. Gennings, J. L. Olmo, S. Ventura, K. J. Cios y J. N. Clore, “Impact of HbA1c Measurement on Hospital Readmission Rates: Analysis of 70,000 Clinical Database Patient Records,” *BioMed Research International*, vol. 2014, 2014.
- [2] A. Rajkomar, J. Dean e I. Kohane, “Machine Learning in Medicine,” *New England Journal of Medicine*, vol. 380, núm. 14, pp. 1347–1358, 2019.
- [3] S. M. Lundberg y S.-I. Lee, “A Unified Approach to Interpreting Model Predictions,” en *Advances in Neural Information Processing Systems*, 2017.
- [4] S. Wachter, B. Mittelstadt y C. Russell, “Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR,” *Harvard Journal of Law & Technology*, vol. 31, núm. 2, pp. 841–887, 2018.
- [5] R. K. Mothilal, A. Sharma y C. Tan, “Explaining Machine Learning Classifiers through Diverse Counterfactual Explanations,” en *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*, pp. 607–617, 2020.
- [6] C. Dwork, “Differential Privacy,” en *Automata, Languages and Programming*, pp. 1–12, Springer, 2006.
- [7] N. Holohan, S. Braghin, P. Mac Aonghusa y K. Levacher, “Diffprivlib: The IBM Differential Privacy Library,” *arXiv preprint arXiv:1907.02444*, 2019.

A. Contribución individual

Tabla 8: Contribución de cada miembro del grupo.

Miembro	Contribución principal
Irene Alavés	2.2, 4.2, 4.3, Protocolo de evaluación, 5.2.1.1, Conclusión
Claudia Fernández	Introducción, 2.1, 4.5.1, 5.2.1.2, 6.1.1, Conclusión
Eva Graña	2.3, 3, 4.1, 4.5.2, 5.2.1.3, Conclusión
Blanca Xifra	2.4, 4.6, 5.2.2, 6.3, Limitaciones, Conclusión

B. Enlace al repositorio

El código fuente del trabajo está disponible en: https://github.com/blancaxifra/proyecto_aprendizaje

C. Uso de herramientas de IA generativa

Orientación

Indica si has utilizado herramientas de IA generativa (ChatGPT, GitHub Copilot, etc.) en la elaboración del trabajo, cómo las has usado y en qué partes. Si no se han utilizado, indícalo explícitamente.

Se han utilizado herramientas de IA generativa, principalmente ChatGPT, como apoyo complementario durante la elaboración del trabajo. Su uso se ha limitado a tareas de orientación, aclaración conceptual, revisión de estilo y apoyo puntual en la estructuración de determinadas secciones.

El contenido principal, el desarrollo, el análisis realizado, la interpretación de resultados y las conclusiones del trabajo han sido elaborados por nosotras, utilizando las herramientas de IA únicamente como recurso auxiliar de apoyo y no como medio principal de generación del mismo.

No obstante, en el apartado de Trabajos Relacionados hemos hecho un uso intensivo de IA para buscar fuentes válidas de las que extraer información con mayor rapidez.